

5.2.5 について、詳細を見ていく。適宜、文献 [7](日本語版の書籍を参考にしている),[47], [83] (<https://tminka.github.io/papers/ep/minka-thesis.pdf>) も参照する。

(5.54)-(5.58) までは仮定なので良いとする。

5.2.5.3 から検討が始まる。

まず、 $m_{i,j}^{(l)} = 0, v_{i,j}^{(l)} = \infty, \alpha_{\gamma_y} = 1, \beta_{\gamma_y} = 0, \alpha_{\gamma_w} = 1, \beta_{\gamma_w} = 0$ とする。これはガウス分布、ガンマ分布の係数となっているので、

$$\mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{(l)}, v_{i,j}^{(l)}) = \frac{1}{2\pi\sqrt{v_{i,j}^{(l)}}} \exp^{-\frac{1}{2v_{i,j}^{(l)}}(w_{i,j}^{(l)} - m_{i,j}^{(l)})^2} \quad (1)$$

$m_{i,j}^{(l)}$ が有限で $v_{i,j}^{(l)} = \infty$ なので、 $\exp^{-\frac{1}{2v_{i,j}^{(l)}}(w_{i,j}^{(l)} - m_{i,j}^{(l)})^2}$ が 1 になる。つまり、一様分布となる。

$$\text{Gam}(\gamma | \alpha, \beta) = C_G(\alpha, \beta) \gamma^{\alpha-1} \exp^{-\beta\gamma} = C_G(1, 0) \gamma^0 \exp^0 = C_G(1, 0) \quad (2)$$

となり、一様分布になる。

本文では仮定密度フィルタリングを利用して、パラメータを決めることとしているし、[47] でも同様の流れとなっている。しかし、[47] の supplemental material の 6 では EP 法を用いた方法が、記載されている。[83] の (3.62) 式の下にあるように、仮定密度フィルタリングは EP 法を 1 サイクル実施したときと等価になるため、それを考慮する。(本の仮定密度フィルタリングのところは $p(\theta|D) \propto p(D|\theta)p(\theta)$ をもととしているが、 $p(W)$ について、 $p(D|W)$ に見えないので、EP 法を踏まえた方法をやってみた。)

(5.57) は [7] の (10.188) のような形式で表されていることがわかる。そのため、EP 法が適用できる。

[47] の supplemental material の 6 で (29),(30) 式はそのまま記載されている。

さて、(4.81),(4.84) を考慮すると、 $\theta = \{\{w_{i,j}^{(l)}\}, \gamma_w, \gamma_y\}, X = \{\}$ として、

$$p(W, \gamma_w, \gamma_y) = p(W|\gamma_w)p(\gamma_w)p(\gamma_y) = \left(\prod_l \prod_i \prod_j \mathcal{N}(w_{i,j}^{(l)} | 0, \gamma_w^{-1}) \right) \text{Gam}(\gamma_w | \alpha_{\gamma_w 0}, \beta_{\gamma_w 0}) \text{Gam}(\gamma_y | \alpha_{\gamma_y 0}, \beta_{\gamma_y 0}) \quad (3)$$

一方で、(30) はそのままとなり、

$$q(W, \gamma_w, \gamma_y) = \left(\prod_l \prod_i \prod_j \mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{(l)}, v_{i,j}^{(l)}) \right) \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}) \text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y}) \quad (4)$$

このとき、(4.81) を考慮すると、

$$\begin{aligned} p(W, \gamma_w, \gamma_y) &= \prod_l \prod_i \prod_j f(w_{i,j}^{(l)}, \gamma_w) f_{\gamma_w}(\gamma_w) f_{\gamma_y}(\gamma_y) \\ f(w_{i,j}^{(l)}, \gamma_w) &= p(w_{i,j}^{(l)} | \gamma_w) = \mathcal{N}(w_{i,j}^{(l)} | 0, \gamma_w^{-1}) \\ f_{\gamma_w}(\gamma_w) &= p(\gamma_w) = \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}) \\ f_{\gamma_y}(\gamma_y) &= p(\gamma_y) = \text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y}) \end{aligned} \quad (5)$$

同様に (4.84) を考慮して、[47],supplement material(32) を参考に、以下のようにも仮定する。(平均などは異なるが、(4) も成り立っていることに注意する。)

$$\begin{aligned} q(W, \gamma_w, \gamma_y) &= \prod_l \prod_i \prod_j \tilde{f}(w_{i,j}^{(l)}, \gamma_w) \\ \tilde{f}(w_{i,j}^{(l)}, \gamma_w) &= \mathcal{N}(w_{i,j}^{(l)} | \tilde{m}_{i,j}^{(l)}, \tilde{v}_{i,j}^{(l)}) \text{Gam}(\gamma_w | \tilde{\alpha}_{i,j}^{(l)}, \tilde{\beta}_{i,j}^{(l)}) \end{aligned} \quad (6)$$

EP 法では (4.86) を考慮する。

$$\begin{aligned}
q^{\setminus i,j,k}(w_{i,j}^{(l)}, \gamma_w) &\equiv \prod_l \prod_i \prod_j \left(\mathcal{N}(w_{i,j}^{(l)} | m^{\setminus i,j,l}, v^{\setminus i,j,l}) \text{Gam}(\gamma_w | \alpha^{\setminus i,j,l}, \beta^{\setminus i,j,l}) \right) \\
&= \frac{q^{old}(w_{i,j}^{(l)}, \gamma_w)}{\tilde{f}(w_{i,j}^{(l)}, \gamma_w)} = \frac{\left(\prod_l \prod_i \prod_j \mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{old(l)}, v_{i,j}^{old(l)}) \right) \text{Gam}(\gamma_w | \alpha_{\gamma_w^{old}}, \beta_{\gamma_w^{old}}) \text{Gam}(\gamma_y | \alpha_{\gamma_{y0}}, \beta_{\gamma_{y0}})}{\mathcal{N}(w_{i,j}^{(l)} | \tilde{m}_{i,j}^{(l)}, \tilde{v}_{i,j}^{(l)}) \text{Gam}(\gamma_w | \tilde{\alpha}_{i,j}^{(l)}, \tilde{\beta}_{i,j}^{(l)})} \\
&\propto \frac{\mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{old(l)}, v_{i,j}^{old(l)})}{\mathcal{N}(w_{i,j}^{(l)} | \tilde{m}_{i,j}^{(l)}, \tilde{v}_{i,j}^{(l)})} \frac{\gamma_w^{\alpha_{\gamma_w^{old}}-1} \exp(-\beta_{\gamma_w^{old}} \gamma_w)}{\gamma_w^{\tilde{\alpha}_{i,j}^{(l)}-1} \exp(-\tilde{\beta}_{i,j}^{(l)} \gamma_w)} \\
&= \mathcal{N}(w_{i,j}^{(l)} | (v_{i,j}^{old(l)-1} - (\tilde{v}_{i,j}^{(l)})^{-1})^{-1} (m_{i,j}^{old(l)} v_{i,j}^{old(l)-1} - \tilde{m}_{i,j}^{(l)} (\tilde{v}_{i,j}^{(l)})^{-1}), (v_{i,j}^{old(l)-1} - (\tilde{v}_{i,j}^{(l)})^{-1})^{-1}) \\
&\quad \gamma_w^{(\alpha_{\gamma_w^{old}} - \tilde{\alpha}_{i,j}^{(l)} + 1) - 1} \exp(-(\beta_{\gamma_w^{old}} - \tilde{\beta}_{i,j}^{(l)}) \gamma_w)
\end{aligned} \tag{7}$$

これにより [47]supplement material の (36)(37) が求まる。

この $q^{\setminus i,j,k}$ を用いて、 q^{new} のパラメータを求める。

(4.87) を考慮して、

$$\begin{aligned}
r(W, \gamma_w, \gamma_y) &= \frac{1}{Z_0} f(w_{i,j}^{(l)}, \gamma_w) q^{\setminus i,j,k}(w_{i,j}^{(l)}, \gamma_w) \\
&= \mathcal{N}(w_{i,j}^{(l)} | 0, \gamma_w^{-1}) \mathcal{N}(w_{i,j}^{(l)} | m^{\setminus i,j,l}, v^{\setminus i,j,l}) \text{Gam}(\gamma_w | \alpha^{\setminus i,j,l}, \beta^{\setminus i,j,l})
\end{aligned} \tag{8}$$

Z_0 を求めると、

$$\begin{aligned}
Z_0 &= \int f(w_{I,J}^{(L)}, \gamma_w) q^{\setminus I,J,L}(w_{I,J}^{(L)}, \gamma_w) \prod_i \prod_j \prod_l dw_{i,j}^{(l)} d\gamma_w d\gamma_y \\
&= \int \mathcal{N}(w_{I,J}^{(L)} | 0, \gamma_w^{-1}) q^{\setminus I,J,L}(w_{I,J}^{(L)}, \gamma_w) \prod_i \prod_j \prod_l dw_{i,j}^{(l)} d\gamma_w d\gamma_y \\
&= \int \mathcal{N}(w_{I,J}^{(L)} | 0, \gamma_w^{-1}) \mathcal{N}(w_{I,J}^{(L)} | m^{\setminus I,J,L}, v^{\setminus I,J,L}) \text{Gam}(\gamma_w | \alpha^{\setminus I,J,L}, \beta^{\setminus I,J,L}) dw_{I,J}^{(L)} d\gamma_w
\end{aligned} \tag{9}$$

I, J, L でないところは $q^{\setminus I,J,L}$ が分布のため、積分すると 1 になる。(というか、正規化定数に含まれる)

一般に (4.60)-(4.62) は成立しているので、

$$\mathbb{E}_r[w_{I,J}^{(L)}] = m_{i,j}^{new(l)} = m^{\setminus I,J,L} + v^{\setminus I,J,L} \frac{\partial}{\partial m^{\setminus I,J,L}} \ln Z_0 \tag{10}$$

同様に (4.63),(4.64),(4.66) も成り立っているので、

$$v_{i,j}^{new(l)} = v^{\setminus I,J,L} - v^{\setminus I,J,L^2} \left(\left(\frac{\partial}{\partial m^{\setminus I,J,L}} \ln Z_0 \right)^2 - 2 \frac{\partial}{\partial v^{\setminus I,J,L}} \ln Z_0 \right) \tag{11}$$

更に、(4.67) に対して、(4.69)-(4.71) が成立するので、(4.72),(4.73) すなわち、(5.62),(5.63) が成り立つ。

$$\alpha_{\gamma_w}^{new} = \left(\frac{Z_2 Z_0 (\alpha^{\setminus I,J,L} + 1)}{Z_1^2 \alpha^{\setminus I,J,L}} - 1 \right)^{-1} \tag{12}$$

$$\beta_{\gamma_w}^{new} = \left(\frac{Z_2 (\alpha^{\setminus I,J,L} + 1)}{Z_1 \beta^{\setminus I,J,L}} - \frac{Z_1 \alpha^{\setminus I,J,L}}{Z_0 \beta^{\setminus I,J,L}} \right)^{-1} \tag{13}$$

最後に \tilde{f} の更新を考える。

$$\begin{aligned}
\tilde{f}^{new}(w_{i,j}^{(l)}, \gamma_w) &\equiv \mathcal{N}(w_{i,j}^{(l)} | \tilde{m}_{i,j}^{new(l)}, \tilde{v}_{i,j}^{new(l)}) \text{Gam}(\gamma_w | \tilde{\alpha}_{i,j}^{new(l)}, \tilde{\beta}_{i,j}^{new(l)}) = Z_0 \frac{q^{new}(w_{i,j}^{(l)}, \gamma_w)}{q^{I,J,L}(w_{i,j}^{(L)}, \gamma_w)} \\
&= Z \frac{\mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{new(l)}, v_{i,j}^{new(l)}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}^{new}, \beta_{\gamma_w}^{new})}{\mathcal{N}(w_{i,j}^{(l)} | m^{i,j,l}, v^{i,j,l}) \text{Gam}(\gamma_w | \alpha^{i,j,l}, \beta^{i,j,l})} = Z \frac{\mathcal{N}(w_{i,j}^{(l)} | m_{i,j}^{new(l)}, v_{i,j}^{new(l)}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}^{new}, \beta_{\gamma_w}^{new})}{\mathcal{N}(w_{i,j}^{(l)} | m^{i,j,l}, v^{i,j,l}) \text{Gam}(\gamma_w | \alpha^{i,j,l}, \beta^{i,j,l})} \\
&= \mathcal{N}(w_{i,j}^{(l)} | (v_{i,j}^{new(l)-1} - v^{i,j,l-1})^{-1} (m_{i,j}^{new(l)} v_{i,j}^{new(l)-1} - m^{i,j,l} v^{i,j,l-1})^{-1}, (v_{i,j}^{new(l)-1} - v^{i,j,l-1})^{-1}) \\
&\quad \gamma_w^{(\alpha_{\gamma_w}^{new} - \alpha^{i,j,l} + 1)^{-1}} \exp(-(\beta_{\gamma_w}^{new} - \beta^{i,j,l}) \gamma_w)
\end{aligned} \tag{14}$$

Z は正規化定数になる。(同じ値とは限らない。)

これにより、[47],supplement material(38),(39) が成り立っていることがわかる。

これが、公式のコードと一致していることを確認する。

ところで、Z は (5.64) のように計算でき、以下ようになる。(別資料のように本文に誤りがある。[47] の (11) も参照のこと。)

$$Z_0 = \mathcal{N}(m^{I,J,L} | 0, v^{I,J,L}) + \frac{\beta_{\gamma_w}^{I,J,L}}{\alpha_{\gamma_w}^{I,J,L} - 1} \tag{15}$$

よって、 $v = v^{I,J,L} + \frac{\beta_{\gamma_w}^{I,J,L}}{\alpha_{\gamma_w}^{I,J,L} - 1}$ として、

$$\begin{aligned}
\ln Z_0 &= \ln \mathcal{N}(m^{I,J,L} | 0, v^{I,J,L}) + \frac{\beta_{\gamma_w}^{I,J,L}}{\alpha_{\gamma_w}^{I,J,L} - 1} \\
&= \ln \mathcal{N}(m^{I,J,L} | 0, v) = -\ln v - \frac{1}{2} m^{I,J,L^2} v + C
\end{aligned} \tag{16}$$

これを考えると Z_1, Z_2 とこれらの微分が求まる。

theano 版のコード (prior.py) を確認すると、以下のようにになっている。

```
import numpy as np
```

```
class Prior:
```

```
    def __init__(self, layer_sizes, var_targets):
```

```
        # We refine the factor for the prior variance on the weights
```

```
        n_samples = 3.0
```

```
        v_observed = 1.0
```

```
# alpha_gamma w0
```

```
        self.a_w = 2.0 * n_samples
```

```
# beta_gamma w0
```

```
        self.b_w = 2.0 * n_samples * v_observed
```

```

# We refine the factor for the prior variance on the noise

n_samples = 3.0
a_sigma = 2.0 * n_samples
b_sigma = 2.0 * n_samples * var_targets

self.a_sigma_hat_nat = a_sigma - 1
self.b_sigma_hat_nat = -b_sigma

# We refine the gaussian prior on the weights

self.rnd_m_w = []
self.m_w_hat_nat = []
self.v_w_hat_nat = []
self.a_w_hat_nat = []
self.b_w_hat_nat = []

for size_out, size_in in zip(layer_sizes[ 1 : ], layer_sizes[ : -1 ]):
# 平均  $m$  を平均 0, 分散 1 で  $m$  をサンプリングする。
# 平均は  $1/\sqrt{\text{size\_in} + 1}$  にしかっていないので更に割る。
    self.rnd_m_w.append(1.0 / np.sqrt(size_in + 1) *
        np.random.randn(size_out, size_in + 1))
#  $\tilde{f}$  に関して  $\tilde{m}/\tilde{v}$  を 0 で初期化。
# これは  $\tilde{m}$  が (33) のように 0 なので、0 になる。
    self.m_w_hat_nat.append(np.zeros((size_out, size_in + 1)))
#  $\tilde{f}$  に関して  $1/\tilde{v}$  を初期化 (33)
    self.v_w_hat_nat.append((self.a_w - 1) / self.b_w * \
        np.ones((size_out, size_in + 1)))
#  $\tilde{f}$  に関して  $(\tilde{\alpha} - 1)$  を 0 で初期化
    self.a_w_hat_nat.append(np.zeros((size_out, size_in + 1)))
#  $\tilde{f}$  に関して  $\tilde{\beta}$  を 0 で初期化
    self.b_w_hat_nat.append(np.zeros((size_out, size_in + 1)))

def get_initial_params(self):

    m_w = []
    v_w = []
    for i in range(len(self.rnd_m_w)):
        m_w.append(self.rnd_m_w[ i ])
        v_w.append(1.0 / self.v_w_hat_nat[ i ])

```

```

        return { 'm_w': m_w, 'v_w': v_w, 'a': self.a_sigma_hat_nat + 1,
                  'b': -self.b_sigma_hat_nat }

def get_params(self):

    m_w = []
    v_w = []
    for i in range(len(self.rnd_m_w)):
        m_w.append(self.m_w_hat_nat[ i ] / self.v_w_hat_nat[ i ])
        v_w.append(1.0 / self.v_w_hat_nat[ i ])

    return { 'm_w': m_w, 'v_w': v_w, 'a': self.a_sigma_hat_nat + 1,
            'b': -self.b_sigma_hat_nat }

#params には  $q^{\text{old}}$  の  $m_{\{i, j\}^{\{1\}}}$ ,  $v_{\{i, j\}^{\{1\}}}$  のデータが含まれる。
def refine_prior(self, params):
# ここの i はレイヤの数→1
    for i in range(len(params[ 'm_w' ])):
# ここの j はレイヤの出力数→i
        for j in range(params[ 'm_w' ] [ i ].shape[ 0 ]):
# ここの k はレイヤの出力数→j
            for k in range(params[ 'm_w' ] [ i ].shape[ 1 ]):

                # We obtain the parameters of the cavity distribution
#  $q^{\text{old}}$  に関して  $v_w$  が来るので  $1 / v_w$  で逆数を取る。
                v_w_nat = 1.0 / params[ 'v_w' ] [ i ] [ j, k ]
#  $q^{\text{old}}$  に関して  $mv^{-1}$  を計算する。
                m_w_nat = params[ 'm_w' ] [ i ] [ j, k ] / \
                    params[ 'v_w' ] [ i ] [ j, k ]
# (36) の  $1/v$ 
                v_w_cav_nat = v_w_nat - self.v_w_hat_nat[ i ] [ j, k ]
# (36) の  $m/v$ 
                m_w_cav_nat = m_w_nat - self.m_w_hat_nat[ i ] [ j, k ]
# (36) の  $v$ 
                v_w_cav = 1.0 / v_w_cav_nat
# (36) の  $m$  を求める。  $1/v_w\_cav\_nat = v\_w\_cav$  になる。
                m_w_cav = m_w_cav_nat / v_w_cav_nat
# (37) に関して、 $-(\tilde{\alpha} \gamma w^{\text{old}} - 1)$ 
                a_w_nat = self.a_w - 1
# (37) に関して、 $-(\tilde{\beta} \gamma w^{\text{old}})$ 

```

```

        b_w_nat = -self.b_w
# (37) に関して左辺のマイナス (nat がついているので  $\alpha-1$  になっている。)
        a_w_cav_nat = a_w_nat - self.a_w_hat_nat[ i ][ j, k ]
# (37) に関して左辺のマイナス
        b_w_cav_nat = b_w_nat - self.b_w_hat_nat[ i ][ j, k ]
# (37) の左辺を求める。
        a_w_cav = a_w_cav_nat + 1
# (37) の左辺を求める。
        b_w_cav = -b_w_cav_nat

# よく見ていないが値が悪ければ、更新されなくなりそう。
        if v_w_cav > 0 and b_w_cav > 0 and a_w_cav > 1 and \
            v_w_cav < 1e6:

            # We obtain the values of the new parameters of the
            # posterior approximation

# Z0 の分散
        v = v_w_cav + b_w_cav / (a_w_cav - 1)

# Z1 の分散
        v1 = v_w_cav + b_w_cav / a_w_cav

# Z2 の分散
        v2 = v_w_cav + b_w_cav / (a_w_cav + 1)

# log Z0。定数項は無視。Z0 は  $q^{\{I,J,L\}}$  を見ている。
        logZ = -0.5 * np.log(v) - 0.5 * m_w_cav**2 / v
# log Z1。定数項は無視。Z1 は  $q^{\{I,J,L\}}$  を見ている。
        logZ1 = -0.5 * np.log(v1) - 0.5 * m_w_cav**2 / v1
# log Z2。定数項は無視。Z0 は  $q^{\{I,J,L\}}$  を見ている。
        logZ2 = -0.5 * np.log(v2) - 0.5 * m_w_cav**2 / v2
# log Z0 を  $m_w_cav$  で偏微分
        d_logZ_d_m_w_cav = -m_w_cav / v
# log Z0 を  $v_w_cav$  で偏微分。v に  $v_w_cav$  も含まれる。
        d_logZ_d_v_w_cav = -0.5 / v + 0.5 * m_w_cav**2 / v**2
# 本の (5.59) *_cav を使っていることに注意
        m_w_new = m_w_cav + v_w_cav * d_logZ_d_m_w_cav
# 本の (5.60) *_cav を使っていることに注意
        v_w_new = v_w_cav - v_w_cav**2 * \
            (d_logZ_d_m_w_cav**2 - 2 * d_logZ_d_v_w_cav)
# 本の (5.62) *_cav を使っていることに注意
        a_w_new = 1.0 / (np.exp(logZ2 - 2 * logZ1 + logZ) * \

```

```

        (a_w_cav + 1) / a_w_cav - 1.0)
# 本の (5.63) *_cav を使っていることに注意
        b_w_new = 1.0 / (np.exp(logZ2 - logZ1) * \
            (a_w_cav + 1) / (b_w_cav) - np.exp(logZ1 - \
            logZ) * a_w_cav / b_w_cav)
# 新しい分散の逆数 (\tilde{f} の更新に備える。)
        v_w_new_nat = 1.0 / v_w_new
# 新しい平均を v で割る。(\tilde{f} の更新に備える。)
        m_w_new_nat = m_w_new / v_w_new
#  $\alpha^{\text{new}}$  の -1(nat) を求める。
        a_w_new_nat = a_w_new - 1
#  $\beta^{\text{new}}$  の nat は-にする。
        b_w_new_nat = -b_w_new

        # We update the parameters of the approximate factor,
        # whih is given by the ratio of the new posterior
        # approximation and the cavity distribution

# (38)  $m^{\text{new}}/v^{\text{new}}$ 
        self.m_w_hat_nat[ i ][ j, k ] = m_w_new_nat - \
            m_w_cav_nat
# (38)  $1/v^{\text{new}}$ 
        self.v_w_hat_nat[ i ][ j, k ] = v_w_new_nat - \
            v_w_cav_nat
# (39)  $\alpha^{\text{new}}-1$ 
        self.a_w_hat_nat[ i ][ j, k ] = a_w_new_nat - \
            a_w_cav_nat
# (39)  $-\beta^{\text{new}}$ 
        self.b_w_hat_nat[ i ][ j, k ] = b_w_new_nat - \
            b_w_cav_nat

        # We update the posterior approximation

        params[ 'm_w' ][ i ][ j, k ] = m_w_new
        params[ 'v_w' ][ i ][ j, k ] = v_w_new

        self.a_w = a_w_new
        self.b_w = b_w_new

    return params

```

これまでの計算があっているように感じる。

なお、(4) のみを考慮して、 γ_y, γ_w については $p(\gamma_y), p(\gamma_w)$ をそのままにすると述べられている。これについては、[83] の演習 10.37 で一般的に確認されている。(公式の解答もあり、そこまで難しくなさそう。)

よって、

$$\begin{aligned}\alpha_{\gamma_w} &= \alpha_{\gamma_{w0}} \\ \beta_{\gamma_w} &= \beta_{\gamma_{w0}} \\ \alpha_{\gamma_y} &= \alpha_{\gamma_{y0}} \\ \beta_{\gamma_y} &= \beta_{\gamma_{y0}}\end{aligned}\tag{17}$$

本、[47],supplement material6 にあるように、

$$\begin{aligned}m_{i,j}^{(l)} &= 0 \\ v_{i,j}^{(l)} &= \infty \\ \tilde{m}_{i,j}^{(l)} &= 0 \\ \tilde{v}_{i,j}^{(l)} &= \infty \\ \tilde{\alpha}_{\gamma_w} &= 1 \\ \tilde{\beta}_{\gamma_w} &= 0\end{aligned}\tag{18}$$

こうしたときに、(33)(34) を考えると、最初の取り込みで、 $q^{\setminus I,J,L}$ は γ_w のガンマ分布になるため、

$$\begin{aligned}m^{\setminus I,J,L} &= 0 \\ v^{\setminus I,J,L} &= \infty \\ \alpha_{\gamma_w}^{\setminus I,J,L} &= \alpha_{\gamma_{w0}} \\ \beta_{\gamma_w}^{\setminus I,J,L} &= \beta_{\gamma_{w0}}\end{aligned}\tag{19}$$

(9) で上記の値を代入すると

$$Z_0 = \int \mathcal{N}(w_{I,J}^{(L)} | 0, \gamma_w^{-1}) \text{Gam}(\gamma_w | \alpha^{\setminus I,J,L}, \beta^{\setminus I,J,L}) dw_{I,J}^{(L)} d\gamma_w = \int p(w_{I,J}^{(L)} | \gamma_w) p(\gamma_w) dw_{I,J}^{(L)} d\gamma_w \tag{20}$$

となり、 Z_0 は常に 1 になり、 Z_1, Z_2 も 1 になる。(37) に対して、 $\alpha^{\setminus I,J,L} = \alpha_0, \beta^{\setminus I,J,L} = \beta_0$ になる。Z たちが 1 なので、 $\alpha^{new} = \alpha_0, \beta^{new} = \beta_0$ になり、(39) を使うと、 $\tilde{\alpha}^{new} = \tilde{\alpha}^{old} = 1, \tilde{\beta}^{new} = \tilde{\beta}^{old} = 0$

一方、上記の式で、 $w_{I,J}^{(L)}$ の関数だとすると学生 t 分布の定義になる。(例えば、PRML の (2.158)-(2.166), (B.64)-(B.67), それに関する演習問題を参照のこと。)

直接平均を求めると、PRML の (B.65) から q^{new} の平均は 0 になり、 q^{new} の分散は P.100 の ν, λ を使い、(B.66) に代入すると q^{new} の分散 v は

$$v = \frac{1}{\lambda} \frac{\nu}{\nu - 2} = \frac{\beta_0}{\alpha_0} \frac{2\alpha_0}{2\alpha_0 - 2} = \frac{\beta_0}{\alpha_0 - 1} \tag{21}$$

となり、(34) が求まる。(39) を考慮すると、(33) も求まる。